

SOFIA ROBAYO BONILLA.

- Si $D_1 > 0$ y $D_2 > 0 \rightarrow f$ es estrictamente convexa.
- Si $D_1 > 0$ y $D_2 = 0 \rightarrow f$ es convexa.
- Si $D_1 < 0$ y $D_2 > 0 \rightarrow f$ es estrictamente cóncava.
- Si $D_1 < 0$ y $D_2 = 0 \rightarrow f$ es cóncava.
- Si $D_1 \leq 0$ y $D_2 < 0 \rightarrow$ No se puede determinar.

$$D_1 = F_{xx}$$

$$D_2 = H(x) = \begin{vmatrix} F_{xx} & F_{xy} \\ F_{yx} & F_{yy} \end{vmatrix}$$

Condición necesaria de 1º orden: $\nabla f(\bar{x}) = 0$

Condiciones necesarias de 2º orden: $\nabla f(\bar{x}) = 0$ y $H(x)$ es semidefinida +.

Condición suficiente 2º orden: $\nabla f(\bar{x}) = 0$ y $H(x)$ es definida +. Entonces es un mínimo local estricto de f en Ω .

→ Toda función convexa es cuasi-convexa.

DIRECCIONES FACTIBLES: $d: f(x+\alpha d) \Rightarrow \frac{\partial f(x)}{\partial d} = Df(x)d = d' \nabla f(x)$.

BÚSQUEDA DE LINEA.

FNL-MÉTODOS OPTIMIZACIÓN NO RESTRINGIDA.

Sección áurea - Algoritmo

Paso 0: Long. final de intervalo l , intervalo inicial $[a_0, b_0]$, $k = 0$
 $\lambda_0 = a_0 + (1 - \alpha)(b_0 - a_0)$, $f(\lambda_0)$
 $\mu_0 = a_0 + \alpha(b_0 - a_0)$, $f(\mu_0)$

Paso 1:

if $b_k - a_k < l$ then

Stop, $\lambda^* \in [a_k, b_k]$

else

if $f(\lambda_k) > f(\mu_k)$ then

Go to Paso 2

else

Go to Paso 3

end if

end if

Paso 2 ($f(\lambda_k) > f(\mu_k)$):

$$a_{k+1} = \lambda_k, b_{k+1} = b_k, \lambda_{k+1} = \mu_k$$

$$\mu_{k+1} = a_{k+1} + \alpha(b_{k+1} - a_{k+1})$$

$f(\mu_{k+1})$, $k = k + 1$, Go to Paso 1

Paso 3 ($f(\lambda_k) < f(\mu_k)$):

$$a_{k+1} = a_k, b_{k+1} = \mu_k, \mu_{k+1} = \lambda_k$$

$$\lambda_{k+1} = a_{k+1} + (1 - \alpha)(b_{k+1} - a_{k+1})$$

$f(\lambda_{k+1})$, $k = k + 1$, Go to Paso 1

$$\alpha \approx 0,618$$

Ajuste cuadrático - Algoritmo

Paso 0: Long. final de intervalo l , intervalo inicial $[x_1, x_2, x_3]$, $k = 0$

Paso 1: $x_1, f(x_1); x_2, f(x_2); x_3, f(x_3)$

$\hat{x}_k, f(\hat{x}_k)$

if $x_3 - x_1 < l$ then

Stop, $\hat{x}_k \in [x_1, x_3]$

else

if $\hat{x}_k > x_2$ then

Go to Paso 2

else if $\hat{x}_k < x_2$ then

Go to Paso 3

else if $\hat{x}_k = x_2$ then

Go to Paso 4

end if

end if

Paso 2 ($\hat{x}_k > x_2$):

if $f(\hat{x}_k) \geq f(x_2)$ then intervalo $[x_1, x_2, \hat{x}_k]$, Go to Paso 1

if $f(\hat{x}_k) \leq f(x_2)$ then intervalo $[x_2, \hat{x}_k, x_3]$, Go to Paso 1

Paso 3 ($\hat{x}_k < x_2$):

if $f(\hat{x}_k) \geq f(x_2)$ then intervalo $[\hat{x}_k, x_2, x_3]$, Go to Paso 1

if $f(\hat{x}_k) \leq f(x_2)$ then intervalo $[x_1, \hat{x}_k, x_2]$, Go to Paso 1

Paso 4 ($\hat{x}_k = x_2$):

$$\hat{x}_k = \begin{cases} x_2 + \epsilon/2 & \text{if } x_2 - x_1 < x_3 - x_2 \\ x_2 - \epsilon/2 & \text{if } x_2 - x_1 > x_3 - x_2 \end{cases} \text{ Go to Paso 1}$$

$$\hat{x}_k = \frac{b_{23}f_1 + b_{31}f_2 + b_{12}f_3}{2(a_{23}f_1 + a_{31}f_2 + a_{12}f_3)}$$

$$\text{donde } b_{ij} = x_i^2 - x_j^2$$

$$a_{ij} = x_i - x_j$$

Cabe resaltar que dichos algoritmos son sacados de las diapositivas de clase, se hace la aclaración para evitar problemas de plagio.

Método de Newton - Algoritmo

Paso 0: Punto inicial x_0 , $k = 0$, error ϵ

Paso 1:

$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$
if $|x_{k+1} - x_k| < \epsilon$ then
Stop, $x^* \in [x_{k+1}, x_k]$

else

Repetir

end if

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

→ Valor óptimo satisface $g(\hat{x}) = f'(\hat{x}) = 0$
→ Mínimo de una función

$$x_{i+1} = x_i - \frac{g(x_i)}{g'(x_i)} = x_i - \frac{f'(x_i)}{f''(x_i)}$$

MULTIVARIABLES

OPTIMIZACIÓN MULTIDIMENSIONAL

Método de descenso del gradiente - Algoritmo

Paso 0: Determine $\epsilon > 0$, punto inicial de búsqueda x_1 , $k = 1$

Paso 1:

while $\|\nabla f(x_k)\| > \epsilon$ do

$$d_k = -\nabla f(x_k)$$

$$\lambda_k = \arg\min_{\lambda \geq 0} f(x_k + \lambda d_k)$$

$$x_{k+1} = x_k + \lambda_k d_k$$

$$k = k + 1$$

end while

$f'(x, d) = \nabla f(x)^T d$, d es una dirección de descenso.

la sol. óptima al problema $\min_{\|d\|=1} f'(x, d)$ s.a. $\|d\|=1$ es

$$d = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$$

Escoje dirección d y se hace búsqueda de línea en dirección d .

Rest. de 1º.

Condición 1º orden: $\nabla f(x) + \lambda \nabla h(x) = 0$

Condición 2º orden:

$$L(x, \lambda) = f(x) + \lambda h(x) = F(x) + \dots + \sum_{j=1}^m \lambda_j h_j(x)$$

$$T(x_0) = \{y : D_h(x) y = 0\}$$

Método de descenso del gradiente - Convergencia

- $\Omega = \{x^* : \nabla f(x^*) = 0\}$
- $A = MD$: mapa algorítmico del método de descenso del gradiente
- Si $f \in C^1$, D es un mapa cerrado.
- Si D y M son cerrados, A es cerrado
- Función de descenso: f
- Suponiendo que $\{x_k\}$ permanece en un conjunto compacto, el método de descenso del gradiente definido por el mapa A converge a un punto en Ω

Método de Newton

Usar aproximación cuadrática de la función en x_k :

$$q(x) = f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T H(x_k) (x - x_k)$$

Condición necesaria para un mínimo local de $q(x)$: $\nabla q(x) = 0$

$$\nabla q(x) = \nabla f(x_k) + \frac{1}{2} (H(x_k)(x - x_k) + H(x_k)^T (x - x_k)) - \nabla f(x_k) = H(x_k)(x - x_k) = 0$$

$$H(x_k)x = H(x_k)x_k - \nabla f(x_k)$$

$$x_{k+1} = x_k - H(x_k)^{-1} \nabla f(x_k)$$

$$x_{k+1} = x_k - H(x_k)^{-1} \nabla f(x_k)$$

Suponiendo $\nabla f(\bar{x}) = 0$ y $H(\bar{x}) > 0$ en un mínimo local \bar{x} , $y \in C^2$:

- $H(x_k) > 0$ para todo punto x_k cerca de \bar{x}

- $H(x_k)^{-1}$ bien definida

Equivalente a método de Newton-Raphson para resolver $\nabla f(x) = 0$ (sist. de ecuaciones no lineales):

- En cada iteración se resuelve un sistema lineal
- Sistema lineal: aproximación de primer orden
- Aproximación de primer orden de $\nabla f(x_k) = 0$:

$$\nabla f(x_k) + H(x_k)(x - x_k) = 0$$

- Se encuentra x , que es el nuevo iterado x_{k+1}

CONVERGENCIA

→ NO necesariamente converge

→ $H(x_k)$ puede ser singular.

→ $f(x_{k+1})$ puede ser mayor que $f(x_k)$

→ CONVERGENCIA: $\|x_{k+1} - \bar{x}\| \leq k_1 k_2 \|x_k - \bar{x}\|^2$

Métodos de direcciones conjugadas - Caso cuadrático

- $f(x) = c^T x + \frac{1}{2} x^T H x$ con H simétrica definida positiva

- $\{d_1, \dots, d_n\}$: H -conjugadas

$$x = x_1 + \sum_{j=1}^n \lambda_j d_j$$

$$c(\lambda) = f(x) = f(x_1 + \sum_{j=1}^n \lambda_j d_j)$$

$$x = x_1 + \sum_{j=1}^n \lambda_j d_j$$

$$c(\lambda) = f(x) =$$

$$c^T x_1 + \sum_{j=1}^n \lambda_j c^T d_j + \frac{1}{2} (x_1 + \sum_{j=1}^n \lambda_j d_j)^T H (x_1 + \sum_{j=1}^n \lambda_j d_j)$$

- Por ser H -conjugadas:

$$c(\lambda) = c^T x_1 + \frac{1}{2} x_1^T H x_1 + \sum_{j=1}^n \left(\lambda_j c^T d_j + \lambda_j d_j^T H x_1 + \frac{1}{2} \lambda_j^2 d_j^T H d_j \right)$$

- Valor óptimo de λ_j :

$$\frac{\partial c(\lambda)}{\partial \lambda_j} = c^T d_j + d_j^T H x_1 + \lambda_j d_j^T H d_j = 0$$

$$\lambda_j^* = -\frac{c^T d_j + d_j^T H x_1}{d_j^T H d_j}$$

- Tamaño de paso óptimo en cada dirección d_j